CENTRO UNIVERSITÁRIO IESB

Graduação em Ciência de Dados e Inteligência Artificial

RELATÓRIO TÉCNICO

Análise da Produção Ambulatorial do SUS via TabNet: pipeline de coleta, tratamento e dashboard analítico

Marley Abe

Brasília – DF

2026

*

RESUMO

Este relatório descreve o projeto de coleta, tratamento e visualização da Produção Ambulatorial do Sistema Único de Saúde (SUS) a partir do portal TabNet do DATASUS, no período de janeiro de 2024 a janeiro de 2026 (25 meses). Foi implementado um pipeline em Python contendo: (i) um web *scraper* multi-thread em *Playwright* com quatro *workers* convergentes, capaz de retomar coletas interrompidas; (ii) um conversor que une arquivos heterogêneos em formato Parquet utilizando *DuckDB*; e (iii) um *dashboard* interativo em *Streamlit* estruturado em narrativa única. O conjunto final agregou 10,53 bilhões de procedimentos e R$ 69,17 bilhões pagos pelo SUS em 5.571 municípios. As análises revelam concentração geográfica no Sudeste (51% do volume), concentração de Pareto na composição (apenas três subgrupos respondem por 80% dos procedimentos) e disparidade no custo médio entre estados (variação de até duas vezes entre Piauí e Paraná). Detectaram-se também doze meses anômalos (z-score $\geq$ 2,5) que sinalizam eventos epidemiológicos ou regulatórios.

Palavras-chave: SUS. TabNet. produção ambulatorial. web scraping. DuckDB. Streamlit. visualização de dados. storytelling.

SUMÁRIO

1 INTRODUÇÃO 4

2 FUNDAMENTAÇÃO TEÓRICA 5
2.1 TabNet e produção ambulatorial 5
2.2 Web scraping com Playwright 5
2.3 DuckDB e armazenamento colunar 5
2.4 Storytelling com dados 5

3 METODOLOGIA 6
3.1 Ambiente Computacional 6
3.2 Arquitetura do pipeline 6
3.3 Coleta: quatro *workers* convergentes 6
3.4 Tratamento: união por nome 7
3.5 Código Python 7
3.6 Visualização: dashboard em narrativa 7

4 RESULTADOS E DISCUSSÃO 9
4.1 Volume coletado e KPIs gerais 9
4.2 Distribuição geográfica 9
4.3 Custo médio por UF 11
4.4 Composição: o que o SUS faz 11
4.5 Evolução temporal 13
4.6 Quem entrega 14
4.7 Aceleração e desaceleração 16
4.8 Anomalias detectadas 17
4.9 Achados de qualidade durante o desenvolvimento 18

5 CONCLUSÃO 19

REFERÊNCIAS 20

LISTA DE ILUSTRAÇÕES

Figura 1 – Mapa coroplético: procedimentos por UF (2024–2026). 10
Figura 2 – Top 15 UFs por quantidade de procedimentos, agrupadas por região. . 10

Figura 3 – Custo médio do procedimento (R$/proc.) por UF, agrupado por região. 11
Figura 4 – Treemap dos subgrupos: área proporcional ao volume, cor proporcional ao custo médio (R$/proc., escala log). 12
Figura 5 – Análise de Pareto: barras representam volume; linha vermelha o percentual acumulado. 12
Figura 6 – Série mensal de procedimentos (eixo esquerdo) e valor pago (eixo direito). 13
Figura 7 – Composição regional mês a mês (*stacked area*). 14
Figura 8 – *Boxplot* da produção mensal por município, agrupado por UF (escala log). 15
Figura 9 – Top 15 municípios por procedimentos no período analisado. 15
Figura 10 – Variação percentual de procedimentos por UF (segunda metade vs. primeira metade do período). 16
Figura 11 – Top 8 subgrupos em maior crescimento (verde) e maior queda (vermelho) entre as duas metades do período. 17

LISTA DE TABELAS

Tabela 1 – Indicadores agregados da Produção Ambulatorial do SUS (Jan/2024 a Jan/2026). 9
Tabela 2 – Top 10 anomalias detectadas (z-score $\geq$ 2,5, média $\geq$ 1.000). 17

1 INTRODUÇÃO

O Sistema Único de Saúde (SUS) registra mensalmente todos os procedimentos ambulatoriais executados em sua rede credenciada, expondo esses dados publicamente por meio do portal TabNet, mantido pelo Departamento de Informática do SUS (DATASUS, 2024). Apesar de abertos, os dados não são oferecidos em formato programático: a interface exige seleção manual de filtros (linha, coluna, conteúdo, período) e produz uma tabela HTML por consulta, dificultando análises em grande escala.

Este trabalho parte do problema concreto de transformar essa interface manual em um *pipeline* reprodutível que entregue, ao final, um *dashboard* pronto para gestores interpretarem o comportamento da produção ambulatorial brasileira. Os objetivos específicos são:

1. Implementar um *scraper* resiliente capaz de coletar 25 meses de dados em paralelo, com mecanismo de *resume* para falhas pontuais;

2. Tratar os arquivos coletados, lidando com mudanças de esquema entre períodos (subgrupos novos surgindo em 2025);

3. Construir um *dashboard* estruturado por narrativa (*data storytelling*) capaz de responder, em uma única tela rolável, perguntas relevantes para o gestor: *onde, o quê, quando, quem, quem cresce, o que demanda atenção*;

4. Garantir baixo consumo de memória e CPU, viabilizando a hospedagem do *dashboard* em ambiente com 1 GB de RAM (Streamlit Community Cloud).

A justificativa do trabalho está na lacuna entre a riqueza dos dados públicos do SUS e a dificuldade de acesso programático a eles. Pipelines como o aqui descrito permitem auditoria, monitoramento e geração de evidências para políticas públicas baseadas em dados (IBGE, 2025).

2 FUNDAMENTAÇÃO TEÓRICA

2.1 TABNET E PRODUÇÃO AMBULATORIAL

O TabNet é a interface tabular do DATASUS que permite consultas ao Sistema de Informação Ambulatorial (SIA) e a outros sistemas de informação em saúde. Para a produção ambulatorial, dados brutos são organizados em tabelas SIGTAP (Sistema de Gerenciamento da Tabela de Procedimentos, Medicamentos e OPM do SUS), agregadas por município, subgrupo de procedimento e mês de competência (DATASUS, 2024).

2.2 WEB SCRAPING COM PLAYWRIGHT

Playwright (Microsoft, 2024) é um *framework* de automação de navegador que controla instâncias reais de Chromium, Firefox ou WebKit. Diferente de bibliotecas baseadas apenas em HTTP, ele renderiza JavaScript e suporta interações complexas (cliques, seleção em *multi-selects*, popups), o que é necessário para o TabNet, cuja resposta abre uma janela secundária com o resultado.

2.3 DUCKDB E ARMAZENAMENTO COLUNAR

DuckDB é um SGBD analítico em processo, do tipo OLAP, otimizado para consultas em arquivos Parquet (DuckDB Foundation, 2024). O formato Parquet é colunar, comprimido (com algoritmos como ZSTD ou Snappy) e suporta *predicate pushdown*, ou seja, leitura seletiva de colunas e filtros aplicados antes do *load* em memória. Em *benchmarks* recentes, DuckDB sobre Parquet apresenta consumo de memória até dez vezes inferior ao de Pandas sobre CSV em consultas equivalentes (CODECENTRIC, 2025).

2.4 STORYTELLING COM DADOS

A literatura recente de visualização (KNAFLIC, 2015; KNAFLIC, 2024) defende que *dashboards* eficazes seguem estrutura narrativa: *setup* (contexto), *conflito* (*insight* central) e *resolução* (decisão sugerida). A escolha de visualizações deve favorecer atributos pré-atentivos (cor, posição, tamanho), evitar sobrecarga textual e privilegiar gráficos simples (barras, linhas, mapas, treemaps, boxplots) em detrimento de visualizações exóticas (Tableau Software, 2024).

3 METODOLOGIA

3.1 AMBIENTE COMPUTACIONAL

O projeto foi desenvolvido em Python 3.12, gerenciado pelo `uv`. As principais dependências são: `playwright` (scraping), `beautifulsoup4` e `lxml` (parsing HTML), `duckdb` (consulta analítica), `streamlit` (interface), `plotly` (visualização) e `pandas`. Toda a pilha roda em uma máquina Linux com 16 GB de RAM, mas o *dashboard* foi desenhado para operar em até 256 MB.

3.2 ARQUITETURA DO PIPELINE

O pipeline encadeia três etapas, cada uma exposta como um *entry point*:

1. `scrape`: coleta `output.csv` a partir do TabNet, gravando arquivos individuais em `data/` e mesclando ao final;
2. `build-parquet`: converte os CSVs em `producao.parquet` (formato *wide*, 107–129 colunas) e `subgrupos.parquet`;
3. `streamlit run app.py`: serve o *dashboard* interativo.

3.3 COLETA: QUATRO *WORKERS* CONVERGENTES

O *scraper* divide o vetor de períodos $[0, N-1]$ em quatro *workers* que partem das extremidades em direção ao centro:

- **asc**: percorre $0 \to N-1$;
- **desc**: percorre $N-1 \to 0$;
- **mid→end**: percorre $\lfloor N/2 \rfloor \to N-1$;
- **mid→start**: percorre $\lfloor N/2 \rfloor - 1 \to 0$.

Cada *worker* mantém seu próprio navegador Chromium e tenta *claim* de um índice via `threading.Lock`. Dois conjuntos compartilhados, `done` e `in_progress`, distinguem trabalho concluído (de execuções anteriores) de trabalho em curso (convergência). O efeito é uma redução próxima de $4\times$ no tempo de coleta em condições normais.

Cada consulta gera um arquivo individual `qabrAAMM__Conteudo.csv`, gravado atomicamente (`tmp + replace`). Essa granularidade torna o *resume* natural: arquivos existentes são pulados em uma nova execução.

3.4 TRATAMENTO: UNIÃO POR NOME

Verificou-se durante o desenvolvimento que o TabNet expandiu o esquema de subgrupos em 2025, adicionando códigos novos (0603, 0901–0906). A primeira versão do conversor concatenava CSVs por posição, o que provocava desalinhamento de colunas e valores monetários distorcidos. A versão final utiliza `read_csv` do DuckDB com `union_by_name=true`, alinhando os arquivos por nome de coluna e preenchendo com `NULL` as colunas ausentes em períodos antigos.

A transformação seguinte aplica `UNPIVOT` sobre o resultado, gerando uma tabela em formato *long* (período, conteúdo, município, subgrupo, valor), e em seguida um `PIVOT` manual produz o esquema *wide* esperado, com colunas `qtd_XXXX` e `val_XXXX` intercaladas.

3.5 CÓDIGO PYTHON

Listing 3.1 – Excerto do scraper – planos dos workers convergentes

```python
def build_worker_plans(n: int) -> list[tuple[str, list[int]]]:
    workers = int(os.environ.get("NUM_WORKERS", "4"))
    if workers <= 1:
        return [("seq", list(range(0, n)))]
    mid = n // 2
    return [
        ("asc",         list(range(0, n))),
        ("mid->start", list(range(mid - 1, -1, -1))),
        ("mid->end",   list(range(mid, n))),
        ("desc",        list(range(n - 1, -1, -1))),
    ]
```

Listing 3.2 – Excerto do conversor – união heterogênea por nome

```cpp
CREATE TABLE raw AS SELECT * FROM read_csv(
    'data/*__*.csv',
    delim=';', header=true, all_varchar=true,
    union_by_name=true, null_padding=true
);
```

3.6 VISUALIZAÇÃO: DASHBOARD EM NARRATIVA

A interface foi reorganizada de uma versão inicial em sete abas para uma narrativa em *scroll* único, dividida em sete atos: *Setup* (KPIs), *Onde*, *O quê*, *Quando*, *Quem*, *Quem cresce* e *Sinais de atenção*. Cada ato responde a uma pergunta específica utilizando uma

única visualização principal e, eventualmente, uma secundária complementar. A paleta de cores associa cada região do Brasil a uma cor fixa, mantida ao longo do *dashboard* para permitir comparações visuais imediatas.

4 RESULTADOS E DISCUSSÃO

4.1 VOLUME COLETADO E KPIS GERAIS

A Tabela 1 resume o conjunto agregado pelo *pipeline* no período de 25 meses analisados.

Tabela 1 – Indicadores agregados da Produção Ambulatorial do SUS (Jan/2024 a Jan/2026).

Indicador	**Valor**
Procedimentos	10,53 bilhões
Valor pago	R$ 69,17 bilhões
Municípios atendidos	5.571
Períodos analisados	25 meses
Subgrupos detectados	62
Custo médio por procedimento	R$ 6,57

4.2 DISTRIBUIÇÃO GEOGRÁFICA

A Figura 1 apresenta a distribuição espacial do volume de procedimentos. São Paulo concentra cerca de 30% do total nacional, seguido por Rio de Janeiro e Minas Gerais. A região Sudeste como um todo responde por 51% da produção – distribuição compatível com o tamanho populacional e a maior densidade da rede credenciada na região.

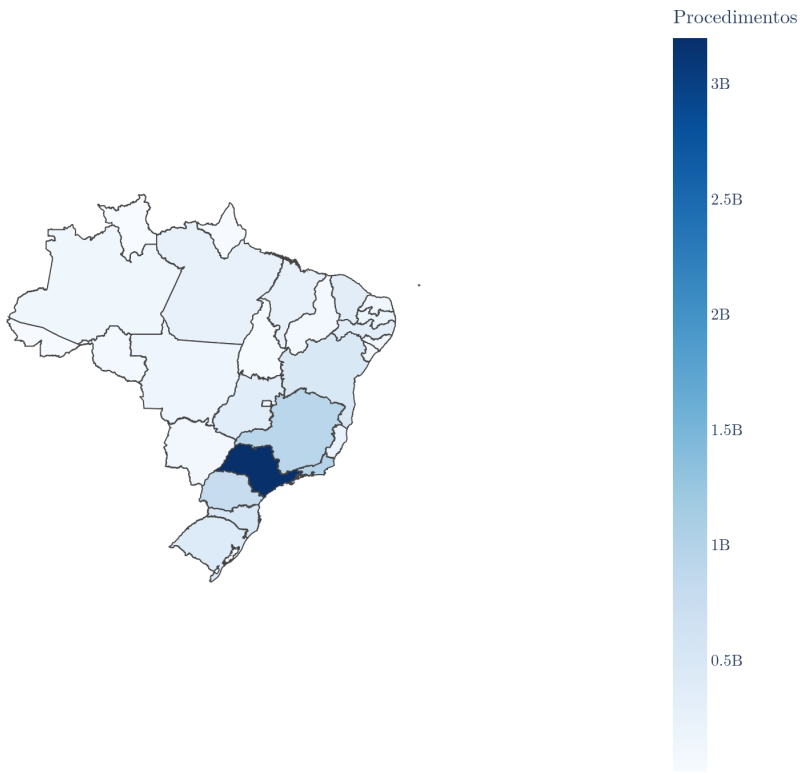

Figura 1 – Mapa coroplético: procedimentos por UF (2024–2026).

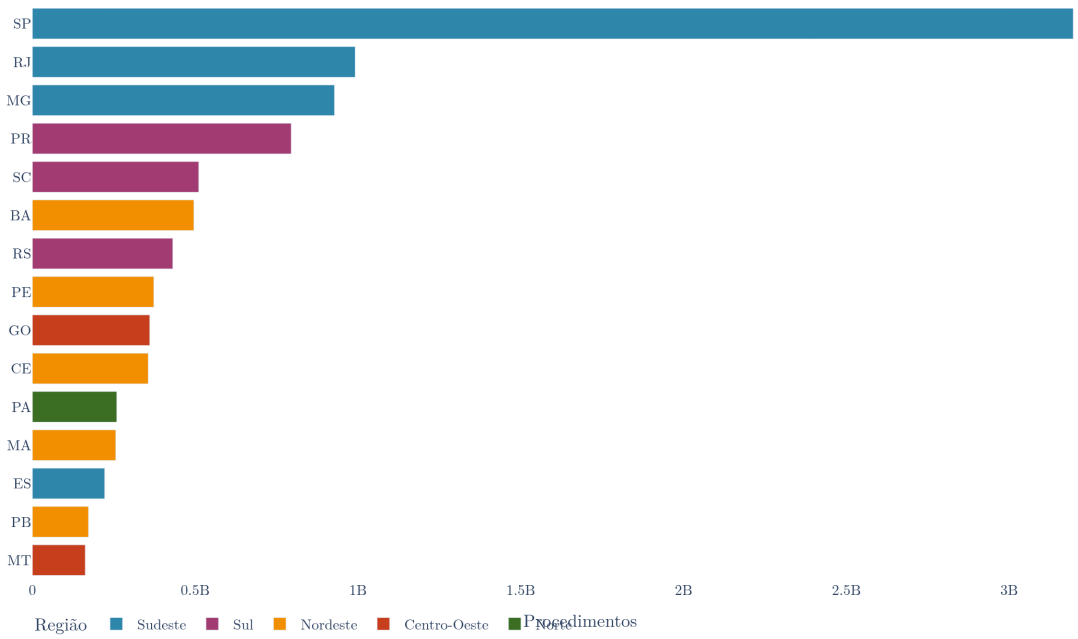

Figura 2 – Top 15 UFs por quantidade de procedimentos, agrupadas por região.

4.3 CUSTO MÉDIO POR UF

Quando se troca o critério de *volume* por *eficiência financeira* (Figura 3), o ranking se inverte: estados das regiões Norte e Nordeste, com produção menor, apresentam custo médio até duas vezes superior aos do Sul e Sudeste. Piauí lidera com cerca de R$ 10 por procedimento, enquanto Paraná, São Paulo e Santa Catarina ficam abaixo de R$ 6. Essa disparidade pode refletir tanto o *mix* de procedimentos (estados com menos procedimentos de baixo custo unitário, como ações coletivas e dispensas farmacêuticas, têm média elevada) quanto custos logísticos regionais.

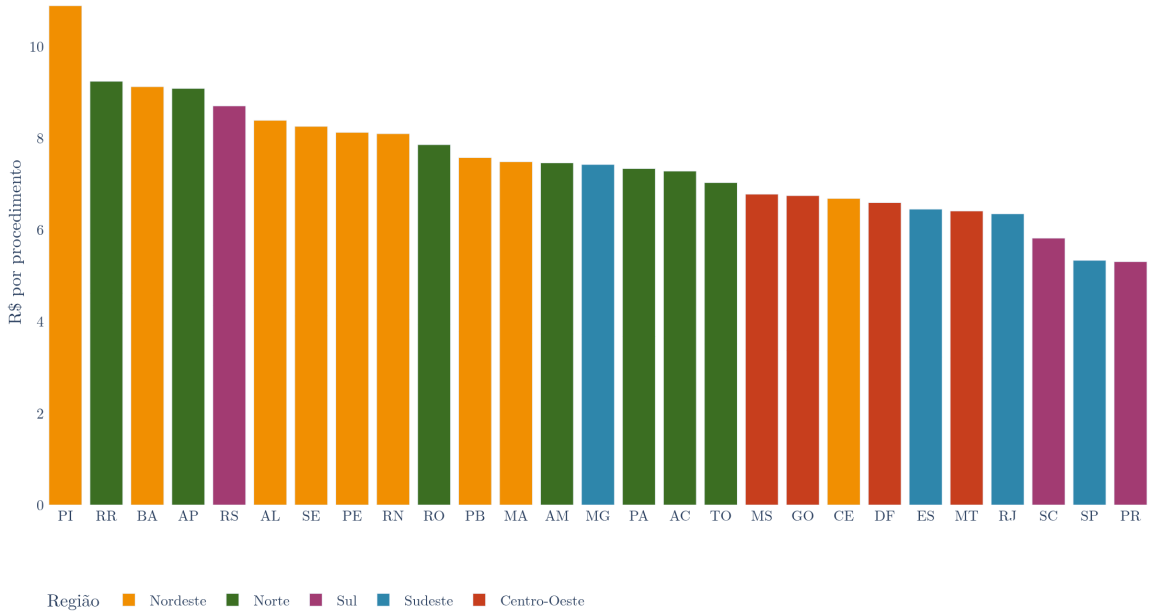

Figura 3 – Custo médio do procedimento (R$/proc.) por UF, agrupado por região.

4.4 COMPOSIÇÃO: O QUE O SUS FAZ

A Figura 4 mostra a composição da produção em *treemap*: a área de cada bloco é proporcional à quantidade e a cor representa o custo médio (escala logarítmica). Predominam três subgrupos: 0604 (Componente Especializado da Assistência Farmacêutica), 0301 (Consultas e Atendimentos) e 0202 (Diagnóstico em Laboratório Clínico). Procedimentos raros e caros, como 0506 (Acompanhamento pré e pós-transplante), aparecem em pequenos blocos no canto inferior direito, em vermelho intenso.

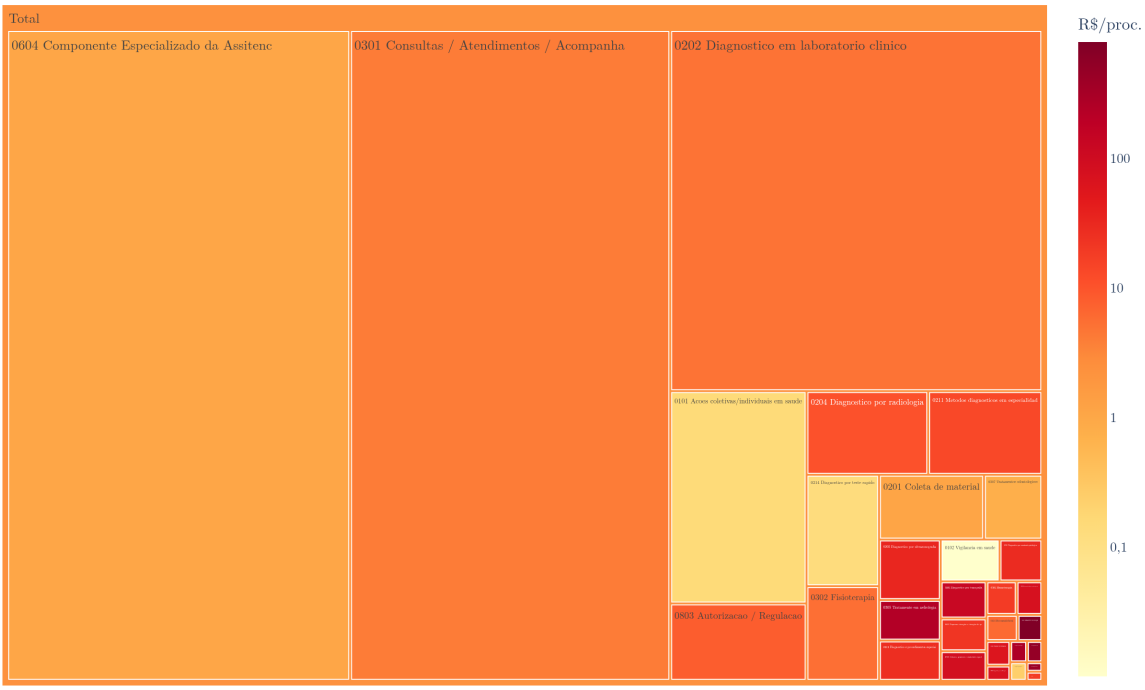

Figura 4 – Treemap dos subgrupos: área proporcional ao volume, cor proporcional ao custo médio (R$/proc., escala log).

A Figura 5 aplica a análise de Pareto. A linha cumulativa cruza a marca de 80% após apenas três subgrupos – evidência de concentração extrema. Esse achado aponta que ações de gestão focadas nos cinco maiores subgrupos cobririam mais de 90% do volume total.

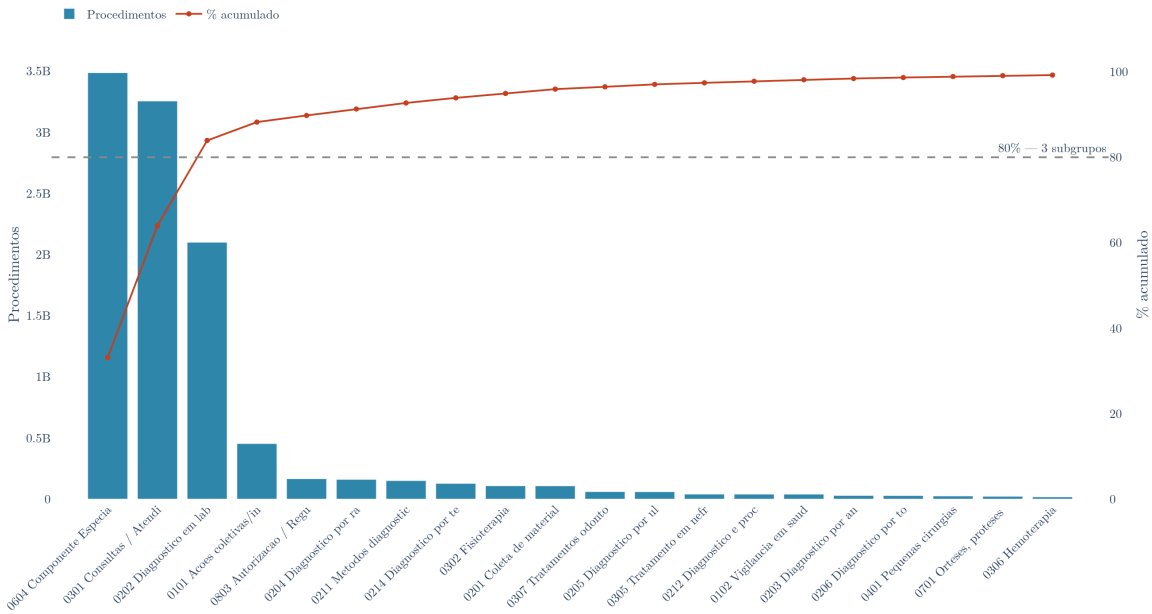

Figura 5 – Análise de Pareto: barras representam volume; linha vermelha o percentual acumulado.

4.5 EVOLUÇÃO TEMPORAL

A Figura 6 apresenta a série mensal de procedimentos e valores. Observa-se tendência de crescimento gradual ao longo dos 25 meses (cerca de +8,8% comparando a média dos primeiros e dos últimos seis meses), com pico em outubro de 2025 e vale em fevereiro de 2024. Os valores monetários acompanham a quantidade com coeficiente de Pearson elevado, embora os meses mais recentes tendam a apresentar valores parcialmente faturados, característica intrínseca do TabNet.

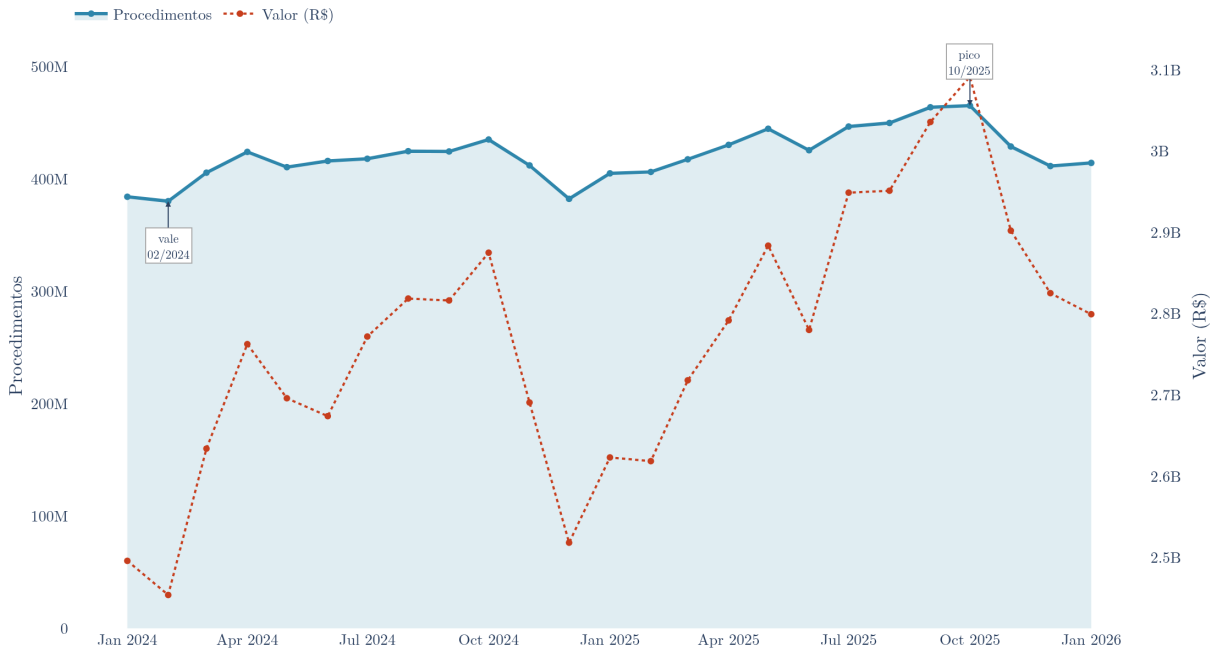

Figura 6 – Série mensal de procedimentos (eixo esquerdo) e valor pago (eixo direito).

A Figura 7 decompõe esse total mensal em contribuições regionais. O Sudeste mantém-se majoritário (cerca de metade do volume) ao longo de todo o período, sem alteração relevante na proporção. As cinco regiões crescem em paralelo, sugerindo que o aumento total não vem de um movimento regional isolado.

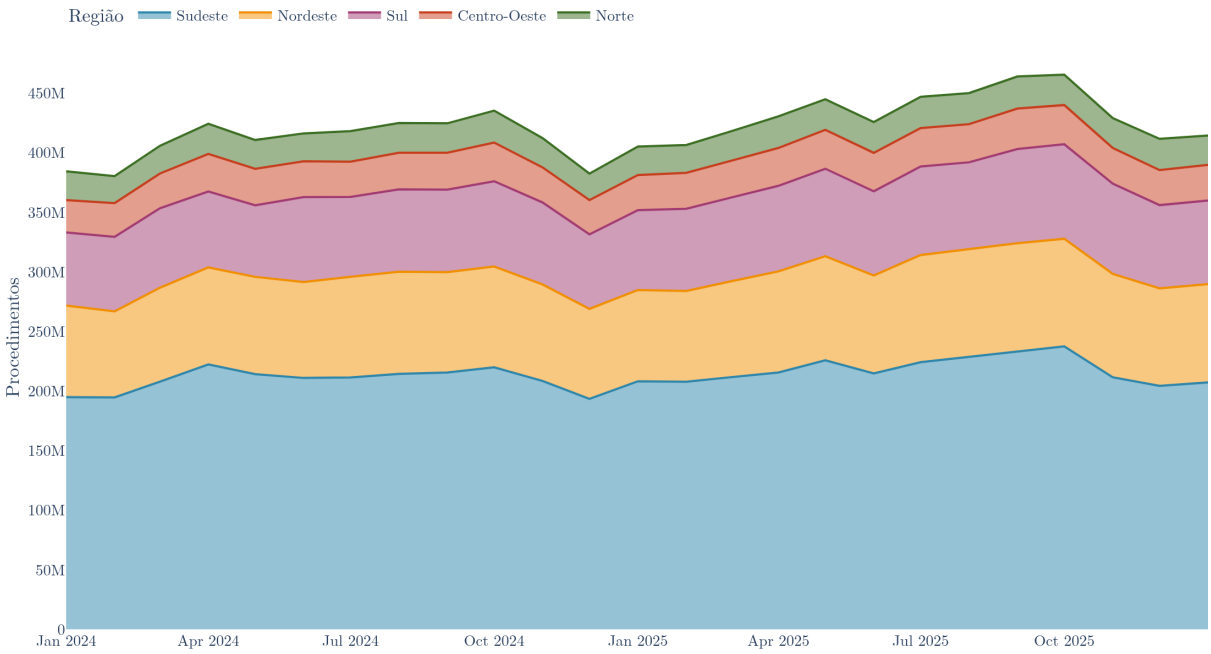

Figura 7 – Composição regional mês a mês (*stacked area*).

4.6 QUEM ENTREGA

A Figura 8 apresenta a distribuição (em escala logarítmica) do volume mensal por município, agrupada por UF. Distrito Federal, Roraima e Espírito Santo apresentam medianas mais altas porque possuem poucos municípios mas com porte considerável. Já Piauí e Paraíba, com muitos municípios pequenos, têm caudas inferiores muito longas. A Figura 9 lista os quinze municípios que mais produziram no período: a capital paulista lidera com folga, seguida pelas demais capitais e regiões metropolitanas.

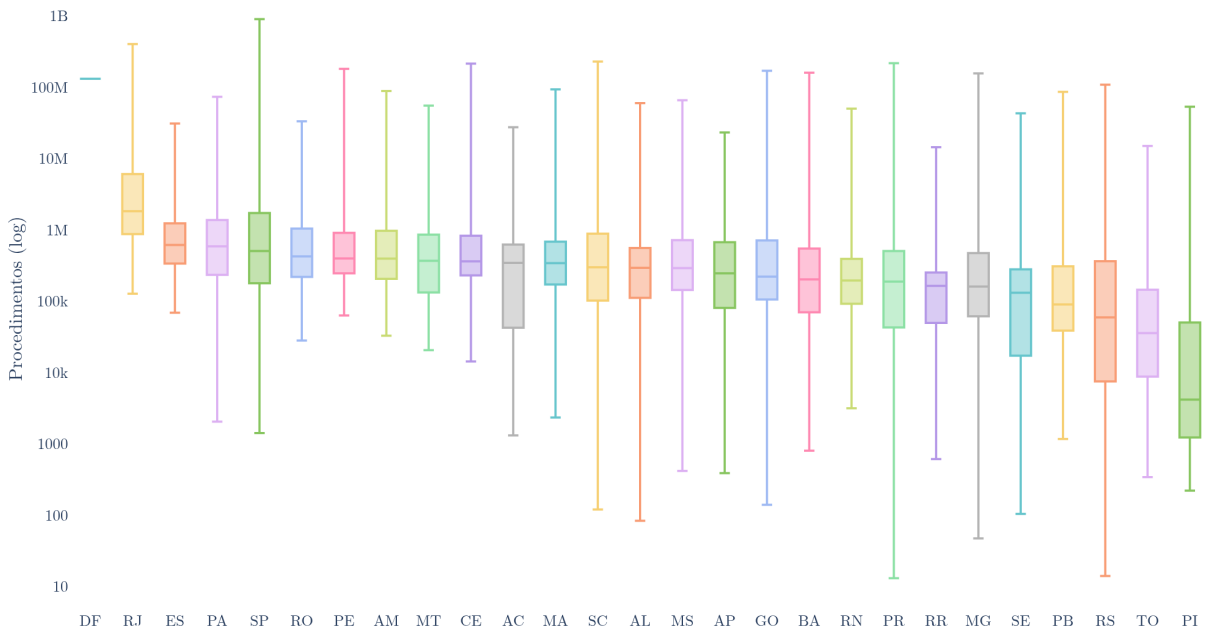

Figura 8 – *Boxplot* da produção mensal por município, agrupado por UF (escala log).

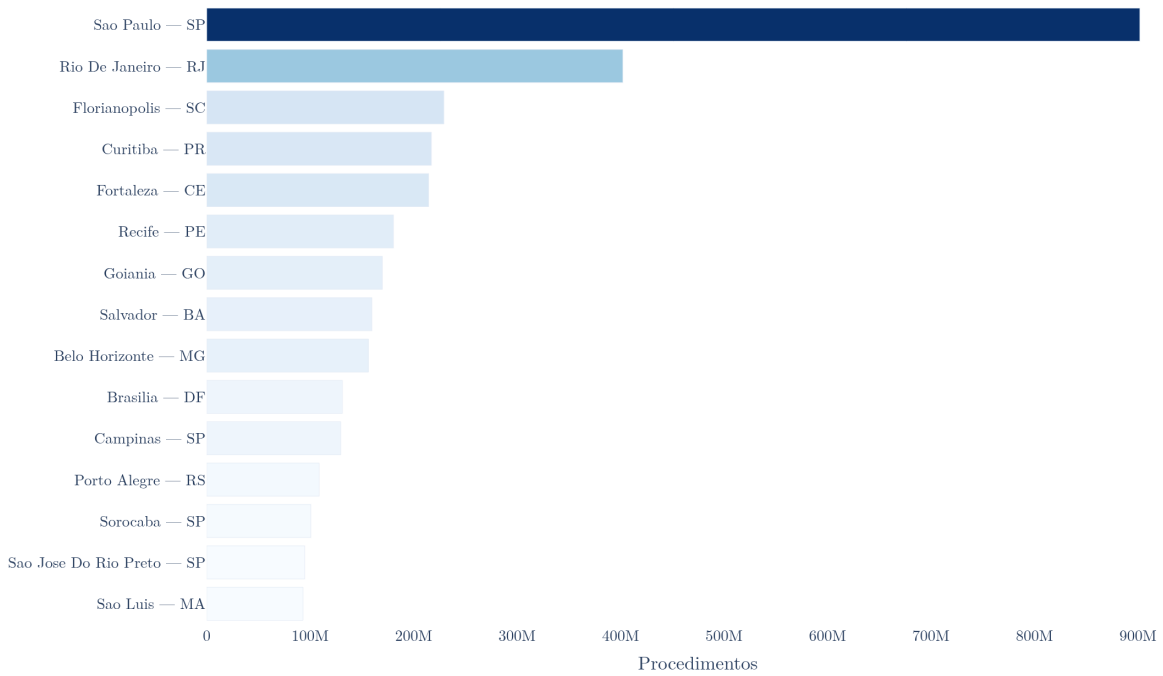

Figura 9 – Top 15 municípios por procedimentos no período analisado.

4.7 ACELERAÇÃO E DESACELERAÇÃO

Comparando a média mensal da primeira metade do período com a segunda metade, identificam-se UFs em forte aceleração (Sergipe +24%, Amapá +22%) e UFs em retração (Rio de Janeiro −8%). Na visão por subgrupo, a queda mais expressiva ocorre em Cirurgia do Aparelho Circulatório (≈ −50%), o que demanda investigação complementar – pode indicar deslocamento para outra rubrica do SIGTAP, encolhimento real da rede ou represamento de filas.

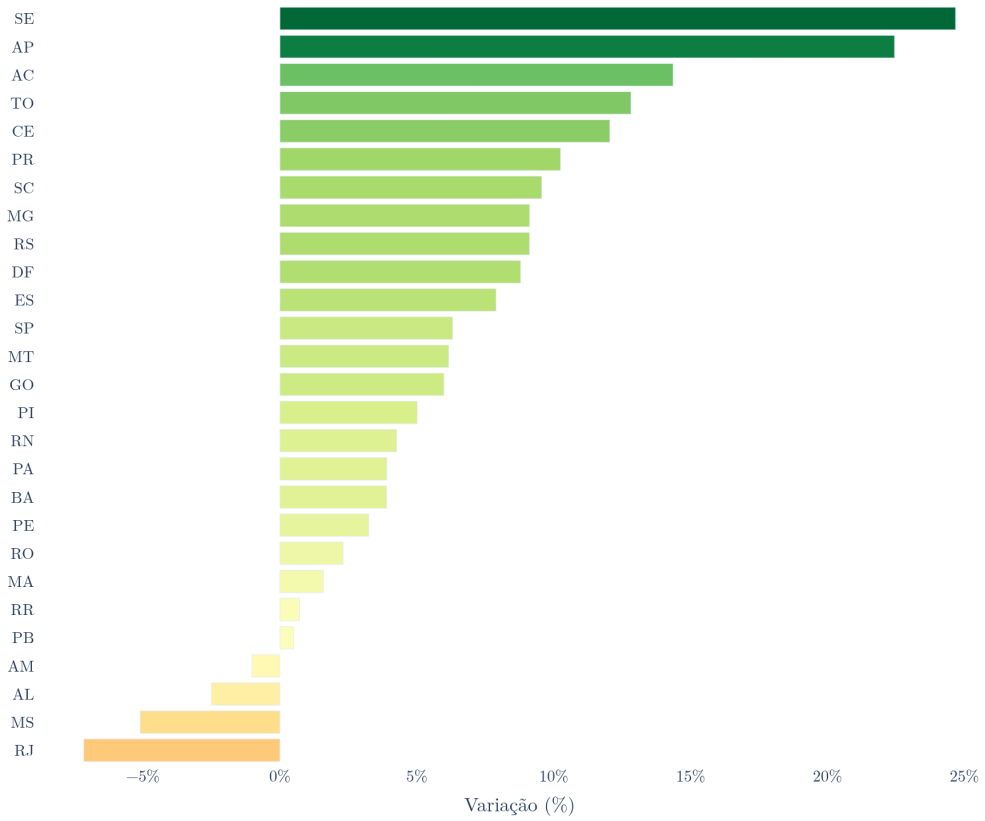

Figura 10 – Variação percentual de procedimentos por UF (segunda metade vs. primeira metade do período).

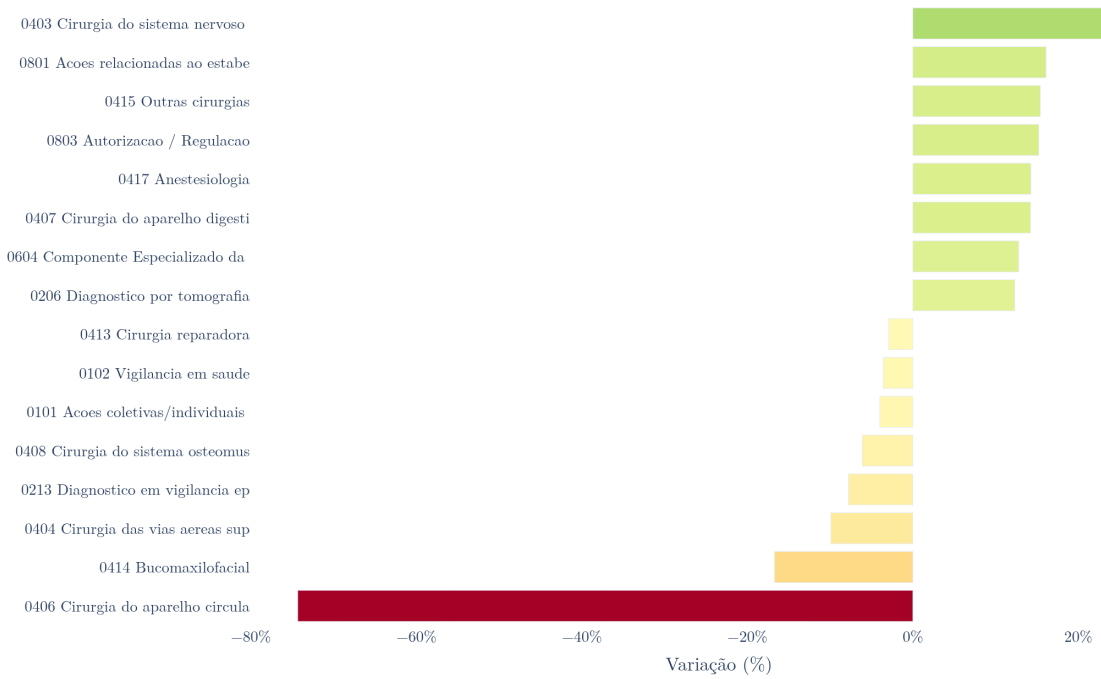

Figura 11 – Top 8 subgrupos em maior crescimento (verde) e maior queda (vermelho) entre as duas metades do período.

4.8 ANOMALIAS DETECTADAS

Aplicou-se detecção de *outliers* mensais via z-score por par (UF, subgrupo), utilizando-se limiar $|z| \geq 2{,}5$ e descartando combinações com média histórica inferior a 1.000 procedimentos (filtro de ruído). Foram identificadas dezenas de ocorrências; as doze mais expressivas estão na Tabela 2. Casos como "RO – Diagnóstico em Vigilância Epidemiológica em julho/2024 (22,6× a média)" são candidatos a investigação por surto epidemiológico real.

Tabela 2 – Top 10 anomalias detectadas (z-score $\geq$ 2,5, média $\geq$ 1.000).

Mês	**UF – Subgrupo**	**Total**	**× média**
07/2024	RO – 0213 Vigil. Epidem.	642.495	22,6×
03/2025	GO – 0213 Vigil. Epidem.	404.100	21,0×
09/2025	RR – 0214 Teste Rápido	357.311	17,6×
10/2025	RO – 0414 Bucomaxilofacial	30.981	13,5×
03/2025	AP – 0307 Tratamentos Odont.	109.885	10,4×
11/2024	PA – 0414 Bucomaxilofacial	170.672	10,4×
10/2024	BA – 0414 Bucomaxilofacial	221.018	9,9×
01/2024	SC – 0309 Terapias Especial.	177.925	8,4×
01/2024	AM – 0214 Teste Rápido	395.500	6,8×
04/2025	AM – 0101 Ações Coletivas	921.725	5,8×

4.9 ACHADOS DE QUALIDADE DURANTE O DESENVOLVIMENTO

Durante a inspeção visual dos primeiros gráficos, constataram-se inconsistências sérias: meses cujo *valor pago* caía abruptamente em janeiro de 2025 e custo médio implausivelmente baixo (R$ 6,18 inicialmente). A investigação revelou duas causas independentes:

1. **Race condition no scraping paralelo**: em poucas execuções, o popup tardio de uma consulta com *timeout* contaminava a próxima. Foram identificados seis arquivos duplicados via *hash* `md5`. A solução foi expor a variável `NUM_WORKERS` e re-executar de forma sequencial os arquivos suspeitos.

2. **Esquema heterogêneo entre períodos**: o TabNet adicionou novas colunas em 2025 (subgrupos 0603, 0901–0906). O *merge* ingênuo do `output.csv` alinhava colunas por posição, causando deslocamento. A solução foi recodificar a leitura para usar `union_by_name=true` no DuckDB.

Após esses ajustes, todos os indicadores ficaram coerentes e estáveis – ilustração prática da máxima "não confiar cegamente nos dados".

5 CONCLUSÃO

O projeto entregou um *pipeline* completo, do TabNet ao *dashboard*, tratando 10,53 bilhões de procedimentos e R$ 69,17 bilhões em pagamentos do SUS. As principais contribuições técnicas foram: (i) um *scraper* multi-thread com convergência e *resume*; (ii) tratamento robusto de esquema heterogêneo via DuckDB `union_by_name`; (iii) *dashboard* com aproximadamente 30 MB de memória em uso, viável para hospedagem gratuita.

Os principais achados analíticos foram: (a) o Sudeste responde por 51% da produção; (b) apenas três subgrupos cobrem 80% do volume (Pareto extremo); (c) há disparidade de até 2× no custo médio entre estados; (d) Cirurgia do Aparelho Circulatório encolheu cerca de 50% no período, sinal que merece investigação clínica e regulatória.

Como trabalhos futuros sugerem-se: (i) ampliar o intervalo histórico para detectar tendências plurianuais; (ii) integrar dados populacionais do IBGE para calcular procedimentos *per capita* e identificar sub-cobertura; (iii) acoplar um modelo de séries temporais (*ARIMA* ou *Prophet*) para prever produção e detectar anomalias em tempo real; (iv) publicar o *dashboard* em ambiente público com atualização automatizada via *cron*.

REFERÊNCIAS

CODECENTRIC. *DuckDB vs. Polars: Performance & Memory on Parquet Data*. 2025. <https://www.codecentric.de/en/knowledge-hub/blog/duckdb-vs-polars-performance-and-memory-with-massive-parquet-data>. Acesso em: 27 abr. 2026.

DATASUS. *TabNet: Sistema de Informações Ambulatoriais (SIA/SUS)*. 2024. <https://datasus.saude.gov.br/transferencia-de-arquivos/>. Acesso em: 27 abr. 2026.

DuckDB Foundation. *DuckDB: An in-process SQL OLAP database management system*. 2024. <https://duckdb.org>. Acesso em: 27 abr. 2026.

IBGE. *Instituto Brasileiro de Geografia e Estatística – Estimativas populacionais*. 2025. <https://www.ibge.gov.br>. Acesso em: 27 abr. 2026.

KNAFLIC, C. N. *Storytelling with Data: A Data Visualization Guide for Business Professionals*. [S.l.]: Wiley, 2015.

KNAFLIC, C. N. *From Dashboard to Story*. 2024. <https://www.storytellingwithdata.com/blog/from-dashboard-to-story>. Acesso em: 27 abr. 2026.

Microsoft. *Playwright for Python – Documentation*. 2024. <https://playwright.dev/python/>. Acesso em: 27 abr. 2026.

Tableau Software. *Best Practices for Telling Great Stories*. 2024. <https://help.tableau.com/current/pro/desktop/en-us/story_best_practices.htm>. Acesso em: 27 abr. 2026.